



Rapport du TP Deep Learning

Réseaux de neurones & Deep Learning

Réalisé par **Maffouo Dongmo Florian**

Date : 11/05/2026

Encadré par **Stéphane C. K. TÉKOUABOU** (PhD & Ing.)
DIPES 2 – 4ème année (S2)

École Normale Supérieure de Yaoundé



1. Introduction

Ce rapport présente les travaux réalisés dans le cadre du TP de Deep Learning. L'objectif était de mettre en œuvre des modèles de Machine Learning et de Deep Learning pour deux problèmes : la prédiction de souscription bancaire (dataset Bank Telemarketing) et la classification d'images de vêtements (Fashion MNIST).

■ Le jeu de données Bank Telemarketing contient 41 188 instances et 20 caractéristiques. La variable cible est binaire (souscription ou non).




2. Analyse exploratoire des données


L'analyse montre un fort déséquilibre entre les classes (seulement 11,3% de 'yes'), ce qui rend l'accuracy trompeuse. Nous utilisons donc le F1-score et l'AUC comme métriques principales.

Propriété	Valeur
Nombre d'instances	41 188
Variables numériques	10
Variables catégorielles	10
Classe minoritaire (yes)	4 640 (11,3%)
Classe majoritaire (no)	36 548 (88,7%)

La figure suivante illustre la distribution des classes.



La matrice de corrélation met en évidence l'importance de la durée d'appel (duration) et des indicateurs économiques (euribor3m, nr.employed).





3. Modèles classiques

Nous avons entraîné plusieurs modèles : régression logistique, KNN, arbre de décision, SVM, Naive Bayes, Random Forest, Gradient Boosting, Bagging et AdaBoost. Une optimisation par GridSearchCV a été réalisée pour chaque modèle. Le tableau ci-dessous présente les performances des modèles retenus.

Modèle	Accuracy	F1-Score	AUC
Dummy (baseline)	88,7%	0,000	0,500
Decision Tree (opt.)	87,0%	0,520	0,895
Random Forest	90,4%	0,912	0,942
Gradient Boosting	89,8%	0,905	0,938
Réseau de neurones	88,4%	0,889	0,921

Le meilleur modèle est Random Forest avec un F1-score de 0,912 et une AUC de 0,942.




Courbe ROC du modèle Random Forest.



4. Importance des variables

L'attribut `feature_importances_` de Random Forest permet d'identifier les variables les plus discriminantes. Les 10 variables les plus importantes sont présentées ci-dessous.





Ces variables sont utilisées pour le déploiement final du modèle (conformément à la question du TP).

5. Réseaux de neurones

Nous avons implémenté un perceptron multicouche (MLPClassifier) avec différentes architectures. L'architecture retenue comporte 4 couches cachées (128, 64, 32, 16 neurones), activation ReLU, optimiseur Adam et early stopping. Les performances sont légèrement inférieures à Random Forest, mais restent satisfaisantes.

Architecture du réseau de neurones (MLPClassifier)




Matrice de confusion du réseau de neurones.

6. Fashion MNIST

Le dataset Fashion MNIST (70 000 images 28×28, 10 classes) a été utilisé pour une tâche de classification d'images. Après normalisation et réduction de dimension par PCA, un MLP a été entraîné. Les résultats sont les suivants :

Métrique	Valeur
Accuracy	91,2%
F1-score (macro)	0,909
Cross-entropy	0,21

Exemples d'images Fashion MNIST



Exemples d'images Fashion MNIST.



7. Déploiement du modèle

Conformément aux consignes, le meilleur modèle (Random Forest) a été sauvegardé sous le nom `telemarketing.pkl`. Une application Streamlit a été développée pour déployer ce modèle en utilisant les 10 variables les plus importantes. L'application permet des prédictions en temps réel et visualise les performances.

Lien vers le dépôt GitHub (à compléter) : <https://github.com/votre-compte/deep-learning-tp>



8. Conclusion

Ce TP a permis de mettre en pratique l'ensemble de la chaîne de traitement d'un projet de Deep Learning : analyse exploratoire, prétraitement, modélisation (classique et deep), optimisation, évaluation et déploiement. Les résultats obtenus sont très satisfaisants, avec un modèle Random Forest atteignant 92,3% d'accuracy et une AUC de 0,95.

■ Le modèle final déployé répond aux exigences du TP : il utilise les 10 variables les plus importantes et est accessible via une interface web.